

Dendê Software House: Implementação do Algoritmo Apriori

Autor: Chaira S. Sacramento
Darlan Deivid S. Silva,
Dylan C. Soares,
Leonardo F. C. Nery

Agenda

O objetivo desta apresentação é ...

1.A Arquitetura do Sistema:

Como construímos o Motor

2. O Desafio da Cardinalidade:

Limpeza Inteligente de Dados

3. O Coração Matemático:

Otimização e Performance

4. Resultados em Tempo Real

Regras de associação geradas pelo algoritmo Apriori.

5. O Valor para o Negócio:

Recomendações para a Dendezeiro

Fluxo de Processamento do Algoritmo



Mineração de Dados

Limpeza Inteligente de Dados



dende-software-association-rule-Vitoria - pre_processing.py

```
18 def carregar_e_limpar_dados(caminho_arquivo):
19
20     #Carrega o dataset
21     df = pd.read_csv(caminho_arquivo)
22
23     #Remover Linhas nulas
24     df = df.dropna(subset=['descricao_produtos', 'id_transacao'])
25
26
27     #Aplica a limpeza, pega a coluna original, passa cada linha da função limpar_descricao e guarda o resultado na nova coluna
28     df['descricao_limpa'] = df['descricao_produtos'].apply(limpar_descricao)
29
30
31     #O dataset original junta todos os produtos de uma mesma compra em um texto apenas
32     #É usado a função anônima lambda para pegar o texto e 'cortar' com split no ponto e vírgula.
33     #O strip() garante que não fique nenhum espaço em branco sobrando no início ou final de cada item
34     df['lista_produto'] = df['descricao_limpa'].apply(
35         lambda texto: [produto.strip().split()[0] for produto in texto.split(';') if produto.strip()]
36     )
37
38     #Pega a coluna 'lista_produto' e converte do formato Pandas para uma lista pura do Python
39     lista_de_vendas = df['lista_produto'].tolist()
40
41     return lista_de_vendas
```

Limpeza Inteligente de Dados

DEMONSTRAÇÃO DO PRÉ-PROCESSAMENTO: DADOS SUJOS VS DADOS LIMPOS

DADOS SUJOS (Como vieram do sistema)

| DADOS LIMPOS (Como o Apriori lê)

KIT MEIA LISA C PARES NO TAG PIMPOLHO UNISSEX A
TOALHA LISA DE ROSTO
CONJ. PAGAO MANGA LISTRA KADOSHINHA;FRALDA X...
SHORT ALGODÃO ELASTICO LISO MIC;SHORT ELASTI...
BERMUDA DE MOLETOM Á SELFIE;CAMISA MACHAO SE...
SUNGA SHORT ESTAMPADA JUVENIL RIO ONDAS
CAMISA MANGA LONGA ESTAMPADA MICOL;CUECAS BO...
CALCINHA ESTAMPADA LUZIANE
CALCINHA ESTAMPADA JUVENIL MALHA ALGODAO JUL...
BLUSA E REGATA CANELADA LISA D'VYSTEK;BLUSA ...

| ['kit']
| ['toalha']
| ['conj.', 'fralda', 'meia']
| ['short', 'short']
| ['bermuda', 'camisa', 'camisa', 'short']
| ['sunga']
| ['camisa', 'cuecas', 'pijama']
| ['calcinha']
| ['calcinha', 'calcinha']
| ['blusa', 'blusa', 'calcinha', 'legue', 'legue', 'prendedor', 'short']

Otimização e Performance



dende-softhouse-association-rule-Vitoria - apriori.py

```
22 #Cria um conjunto vazio e varrem cada peça de roupa vendida e
    tranforma num frozenset
23     itens_unicos = set()
24     for transacao in transactions:
25         for item in transacao:
26             itens_unicos.add(frozenset([item]))
```

Otimização e Performance



dende-softhouse-association-rule-Vitoria - apriori.py

```
11 def _calcular_suporte(self, transactions, candidato):
12     #Percorre as vendas gerando um número "1" sempre que o combo est
13     iver no carrinho de compras e soma retornando o total vendido
14     count = sum(1 for transacao in transactions if candidato.issubset
15     (transacao))
16     #Retorna a porcentagem
17     return count / self.num_transactions
```

Resultados em Tempo Real



#1 mijão -> camiseta
Suporte: 1.46%
Confiança: 33.49%
Lift: 4.21

#2 bermuda -> camisa
Suporte: 3.61%
Confiança: 52.33%
Lift: 3.74

#3 camisa -> bermuda
Suporte: 3.61%
Confiança: 25.75%
Lift: 3.74

#4 short -> regata
Suporte: 4.37%
Confiança: 35.16%
Lift: 3.48

#5 regata -> short
Suporte: 4.37%
Confiança: 43.17%
Lift: 3.48

#6 bermuda -> regata
Suporte: 2.38%
Confiança: 34.59%
Lift: 3.42

#7 regata -> bermuda
Suporte: 2.38%
Confiança: 23.56%
Lift: 3.42

#8 mijão -> camisa
Suporte: 1.62%
Confiança: 37.16%
Lift: 2.65

#9 blusa -> short
Suporte: 2.00%
Confiança: 31.95%
Lift: 2.57

Resultados em Tempo Real



#10 calca -> camisa

Suporte: 1.08%

Confiança: 35.53%

Lift: 2.54

#11 camiseta -> short

Suporte: 2.46%

Confiança: 30.98%

Lift: 2.49

#12 conj -> conjunto

Suporte: 1.14%

Confiança: 26.76%

Lift: 1.89

#13 short -> camisa

Suporte: 2.79%

Confiança: 22.42%

Lift: 1.60

#14 cueca -> camisa

Suporte: 1.44%

Confiança: 21.36%

Lift: 1.53

#15 vestido -> calcinha

Suporte: 2.06%

Confiança: 23.09%

Lift: 1.45

#16 blusa -> calcinha

Suporte: 1.40%

Confiança: 22.36%

Lift: 1.40

#17 short -> calcinha

Suporte: 2.54%

Confiança: 20.48%

Lift: 1.28

PS C:\Users\Chaira\dende

O Valor para o Negócio



Kit Promocional

mijão -> camiseta
Suporte: 1.46%
Confiança: 33.49%
Lift: 4.21

Abordagem de Venda

bermuda -> camisa
Suporte: 3.61%
Confiança: 52.33%
Lift: 3.74

Data Quality

conj -> conjunto
Suporte: 1.14%
Confiança: 26.76%
Lift: 1.89

Referências



- PANDAS DEVELOPMENT TEAM. *Pandas Documentation* (pandas.pydata.org)
- PYTHON SOFTWARE FOUNDATION. *Python Documentation* (docs.python.org/3/)
- AGRAWAL, Rakesh; SRIKANT, Ramakrishnan. *Fast Algorithms for Mining Association Rules*. Proceedings of the 20th International Conference on Very Large Data Bases (VLDB), 1994.